TheoInf 1
Woche 8

Kontextfreie Grammatiken (Fortsetzung)

▸ **Knobelaufgabe**

Welche Sprache erzeugt die folgende Grammatik G?

$S \rightarrow \varepsilon \mid aSbS \mid bSaS$

Produktionsregel 1, Produktionsregel 2, Produktionsregel 3

▸ **Antwort:**

$L = \{w \in \{a, b\}^* \mid w \text{ enthält genau so viele a wie b}\}$

▸ **Beweis:**

Sei L_G sei die Sprache, die G erzeugt. Wir wollen zeigen, dass $L = L_G$.
Wir beweisen das in zwei Teilen:
Teil 1: Wir beweisen, dass $L_G \subseteq L$ ("alle Strings, die die Grammatik erzeugt, enthalten gleich viele a wie b")
Teil 2: Wir beweisen, dass $L \subseteq L_G$ ("alle Strings, die gleich viel a wie b enthalten, werden von der Grammatik erzeugt")

Beweis Teil 1:
Jede Produktionsregel in G erzeugt gleich viele a wie b ⇒ jeder von G erzeugte String enthält gleich viele a wie b ⇒ $L_G \subseteq L$.

Beweis Teil 2:
Beweis mit vollständige Induktion (nach n = die Maximallänge der Strings)
Wir zeigen für alle $n \in \mathbb{N}_0$ die Behauptung B_n : "alle Strings $w \in \{a, b\}^*$ mit einer Länge ≤ n, die gleich viele a wie b enthalten, werden von G erzeugt" = "alle Strings ∈ L mit Länge ≤ n sind auch ∈ L_G".

Induktionsanfang: für n = 0 gilt: der einzige String der Länge 0 ist ε, er enthält gleich viele a wie b (ε ∈ L) und kann von G erzeugt werden (ε ∈ L_G) (mit Produktionsregel 1)

Induktionsschritt: Sei $n \in \mathbb{N}$
- Induktionsannahme: es gelte B_{n-1}
- Induktionsbehauptung: es gilt auch B_n
Sei $w \in L$ ein String der Länge n.
Wir müssen nun zeigen, dass $w \in L_G$.
Der j-te Buchstabe von w sei $c_j \in \{a, b\}$, d.h. $w = c_1c_2...c_n$.
Da n > 0 gilt: $w \neq \varepsilon$ ⇒ es gibt einen ersten Buchstaben c_1 von w.

Fall 1: c_1 = "a"
Wir zerlegen nun w in vier Teile: w = aubv mit u, v ∈ {a, b}*, und sowohl u als auch v enthalten gleich viele a wie b, also u, v ∈ L. ⇦ dass das geht, beweisen wir hier nicht = *Beweislücke!* 😳

Beispiel:

w = $\underbrace{a}_{u}\underbrace{abba}_{u}\underbrace{b}_{v}\underbrace{bbabaa}_{v}$

Da sowohl u als auch v ∈ L und eine Länge ≤ n−1 haben folgt aus der Induktionsannahme, dass u, v ∈ L_G sind. D.h. es gibt für sie Ableitungen S → … → u und S → … → v. Also gibt es insgesamt eine Ableitung S $\underbrace{\rightarrow}_{\text{Regel 2}}$ aSbS → … → aubS → … → aubv = w

⇒ w ∈ L_G

Fall 2: c_1 = "b"
(genau so wie Fall 1, nur dass a und b die Rollen tauschen und am Ende Regel 3 statt Regel 2 verwendet wird).

Da c_1 = "a" oder c_1 = "b" ist, folgt aus Fall 1 und Fall 2 die Induktionsbehauptung B_n.

Aus Induktionsanfang und Induktionsschritt folgt, dass B_n für alle n ∈ $\mathbb{N}_0$ gilt.
Da jeder String ∈ L eine endliche Länge hat, folgt daraus L ⊆ L_G.

Da nun L ⊆ L_G und L_G ⊆ L ist, folgt: L = L_G ▨

Grenzen kontextfreier Grammatiken

▸ Pumping-Lemma für CFG

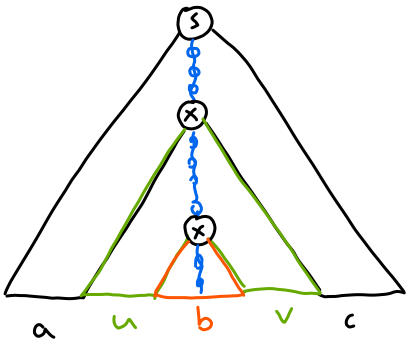
Sei L eine kontextfreie Sprache
wenn L endlich viele Elemente enhält, ist L auch regulär und darum erst recht kontextfrei.
Sei L eine unendlich große Menge ⇒ es gibt beliebig lange Strings w ∈ L.

⇒ es existiert eine CFG, die L produziert
Da jede CFG nur endlich viele Produktionsregeln hat, kann nicht jeder String aus L mit einer eigenen Produktionsregel erzeugt worden sein.

Beobachtung: Je länger w ∈ L wird, desto tiefer wird der Ableitungsbaum.

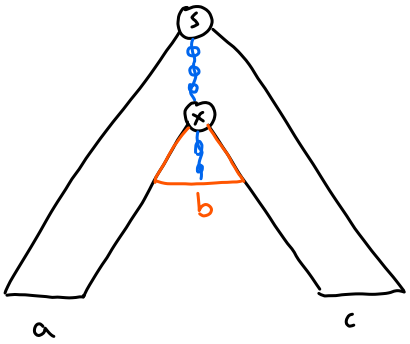
Wähle ein w ∈ L, das so lang ist, dass die Tiefe des Ableitungsbaums größer als die Anzahl der Nichtterminale ist ⇒ auf einem Pfad von der Wurzel zu einem Blatt mit der maximale Länge müssen Nichtterminale mehrfach vorkommen ⇒ man kann w in fünf Teile zerlegen:

w = aubvc



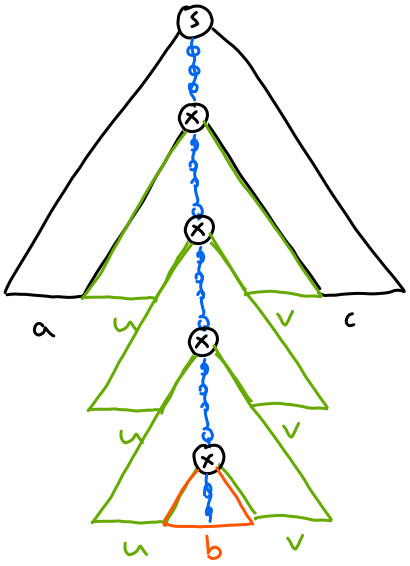
w = aubvc ∈ L

Dann ist aber auch der String abc ∈ L:



abc ∈ L

und auch z.B. $au^3bv^3c \in L$:



auuubvvvc ∈ L

Insgesamt ist dann also auch $w' = au^nbv^nc \in L$, für alle $n \in \mathbb{N}_0$

»Wenn die Sprache beliebig lange Strings enthält,m dann kann ich Strings, die genügend lang sind, "aufpumpen", und zwar an zwei Stellen gleichzeitig.«

▸ **Folgerung**
$L = \{a^nb^nc^n \mid n \in \mathbb{N}_0\}$ ist nicht kontextfrei!

Begründung: Beim "Pumpen" kann man immer höchstens 2 der drei Buchstabengruppen (a, b und c) verändern, die dritte bleibt gleich ⇒ wir können nicht dafür sorgen, dass alle drei Gruppen gleich groß sind.

▸ **Beobachtung 1:** Die Schnittmenge von kontextfreien Sprachen muss nicht unbedingt kontextfrei sein.

Beispiel: Folgende Sprachen sind kontextfrei:

1. $L_1 = \{a^nb^nc^m \mid n, m \in \mathbb{N}_0\}$
2. $L_2 = \{a^nb^mc^m \mid n, m \in \mathbb{N}_0\}$

zu L_1:
S → Sc | X
X → aXb | ε

zu L_2:
S → aS | Y
Y → bYc | ε

Was ist mit $L_1 \cap L_2$?
$L_1 \cap L_2 = \{a^nb^nc^n \mid n \in \mathbb{N}_0\}$ ist nicht kontextfrei!

▸ **Beobachtung 2:** Die Vereinigungsmenge von kontextfreien Sprachen ist kontextfrei.

▸ **Beobachtung 3:** Die inverse Sprache einer kontextfreien Sprache ist nicht unbedingt kontextfrei.

Beispiel:

$L = \{w \in \{a, b\}^* \mid \text{es gibt ein } u \in \{a, b\}^* \text{ mit } w = uu\}$ ⇦ nicht kontextfrei (ohne Beweis)

$L' = \{w \in \{a, b\}^* \mid \text{es gibt } \textit{kein}\ u \in \{a, b\}^* \text{ mit } w = uu\}$ ⇦ das ist kontextfrei

Grammatik für L':

$S \rightarrow \underbrace{A \mid B}_{\substack{\text{ungerade} \\ \text{Länge}}} \mid \underbrace{AB \mid BA}_{\substack{\text{gerade} \\ \text{Länge}}}$

A → CAC | a ⇦ String ungerader Länge mit a in der Mitte
B → CBC | b ⇦ String ungerader Länge mit b in der Mitte
C → a | b